

JEDNORÓWNANIOWY MODEL LINIOWY Z WIELOMA ZMIENNYMI OBJAŚNIAJĄCYMI



Autor: Natalia Then

Data oddania: 24.05.2025

Kierunek: Analityka Biznesowa

Grupa: 3

SPIS TREŚCI

ANALIZA DANYCH RYNKOWYCH	1
SPIS TREŚCI	BŁĄD! NIE ZDEFINIOWANO ZAKŁADKI.
SFORMUŁOWANIE PROBLEMU	3
USTALENIE CZYNNIKÓW WPŁYWAJĄCYCH NA ZJAWISKO	3
ZGROMADZENIE DANYCH.....	4
REDUKCJA ZBIORU ZMIENNYCH	6
DOBÓR POSTACI ANALITYCZNEJ MODELU	9
ESTYMACJA PARAMETRÓW MODELU	10
WERYFIKACJA MODELU	11
ZASTOSOWANIE MODELU I WNIOSKI	19
BIBLIOGRAFIA	20

Rysunek 1 wykres szeregu czasowego- pokazuje zmienność w czasie.....	4
Rysunek 2 prezentacja wszystkich danych.....	5
Rysunek 3 macierz korelacji- ocena współliniowości.....	7
Rysunek 4 ocena współliniowości modelu	7
Rysunek 5 model 1- ze wszystkimi zmiennymi.....	8
Rysunek 6 prezentacja danych bez G.....	8
Rysunek 7 równanie modelu 1 – ze wszystkimi zmiennymi	9
Rysunek 8 równanie modelu 2 - bez zmiennej G	9
Rysunek 9 klasyczna metoda najmniejszych kwadratów- dopasowanie modelu	10
Rysunek 10 wykres rozkładu częstotliwości reszt modelu	11
Rysunek 11 wykres rozkładu reszt	11
Rysunek 12 wykres reszt modelu względem czasu	15
Rysunek 13 wykres empirycznych i wyrównania względem czasu -pokazanie trafności prognozy.....	17
Rysunek 14 przedziały ufności ocen parametrów	18

SFORMUŁOWANIE PROBLEMU

Celem projektu jest zbudowanie modelu ekonometrycznego służącego do wyjaśniania i prognozowania liczby ludności Stanów Zjednoczonych (USA) w latach 1960–1995. Zmienna objaśniana (Pop) wyrażona jest w milionach osób. Prognozowanie populacji ma zastosowanie m.in. w analizach demograficznych, planowaniu polityki społecznej, budżetu państwa oraz rozwoju gospodarczego.

Zakres analizy:

- **Zakres czasowy:** 1960–1995 (36 obserwacji)
- **Zakres przestrzenny:** Stany Zjednoczone
- **Jednostka zmiennej objaśnianej (Pop):** miliony osób


USTALENIE CZYNNIKÓW WPŁYWAJĄCYCH NA ZJAWISKO

Zmienna	Opis	Korelacja z Pop
G	Wydatki rządowe	0.996 ✓
Y	Dochód narodowy	0.994 ✓
Ppt	Produkt na osobę.	0.995 ✓
Puc	Ceny konsumpcyjne.	0.990 ✓
Pd	Produkt Krajowy Brutto	0.986 ✓
Ps	Ceny sprzedaży.	0.983 ✓
Pg	Ceny wyd. rządowych	0.981 ✓
Pn	Dochód netto	0.980 ✓
Pnc	Ceny konsumpcyjne	0.976 ✓


Wszystkie dane zostały przekształcone do postaci umożliwiającej estymację modelu liniowego. Zostały również sprawdzone pod kątem kompletności oraz zakresów wartości. Dane zaimportowano do środowiska Gretl, gdzie przeprowadzono dalsze analizy.

ZGROMADZENIE DANYCH

Dane empiryczne wykorzystane w projekcie pochodzą z wbudowanej bazy danych programu **Gretl**. Obejmują **36 obserwacji rocznych** dla Stanów Zjednoczonych w okresie od **1960 do 1995 roku**.



Rysunek 1 wykres szeregu czasowego- pokazuje zmienność w czasie



Rysunek 2 prezentacja wszystkich danych


REDUKCJA ZBIORU ZMIENNYCH

Zmienna	Opis	Korelacja z Pop
G	Wydatki rządowe	0.996 ✓
Y	Dochód narodowy	0.994 ✓
Ppt	Produkt na osobę	0.995 ✓
Puc	Ceny konsumpcyjne	0.990 ✓
Pd	Produkt Krajowy Brutto	0.986 ✓
Ps	Ceny sprzedaży	0.983 ✓
Pg	Ceny wyd. rządowych	0.981 ✓
Pn	Dochód netto	0.980 ✓
Pnc	Ceny konsumpcyjne netto	0.976 ✓


Na podstawie:

- macierzy korelacji,
- analizy p-value,
- i badania współliniowości (VIF),

usunięto zmienne, które nie były istotne statystycznie (np. $G - p > 0,05$) oraz te, które były nadmiernie skorelowane z innymi (redukcja współliniowości).



Rysunek 3 macierz korelacji- ocena współliniowości



Rysunek 4 ocena współliniowości modelu

gretl: model 1

Model 1: Estymacja KMNK, wykorzystane obserwacje 1960–1995 (N = 36)
Zmienna zależna (Y): Pop

	współczynnik	błąd standardowy	t-Studenta	wartość p	
const	132.500	5.36446	24.70	5.92e-22	***
G	0.0642036	0.0464725	1.382	0.1770	
Pg	1.79963	0.723606	2.487	0.0185	**
Y	0.00641131	0.00190863	3.359	0.0021	***
Ppt	4.21436	0.445256	9.465	1.17e-10	***

Średn. arytm. zm. zależnej	221.9472	Odch. stand. zm. zależnej	24.00839
Suma kwadratów reszt	65.72998	Błąd standardowy reszt	1.456133
Wsp. determ. R-kwadrat	0.996742	Skorygowany R-kwadrat	0.996321
F(4, 31)	2370.909	Wartość p dla testu F	4.65e-38
Logarytm wiarygodności	-61.91844	Kryt. inform. Akaike'a	133.8369
Kryt. bayes. Schwarza	141.7545	Kryt. Hannana-Quinna	136.6003
Autokorel. reszt - rho1	0.516901	Stat. Durbina-Watsona	0.735142

Wyłączając stałą, największa wartość p jest dla zmiennej 1 (G)

Rysunek 5 model 1- ze wszystkimi zmiennymi

P-value > 0,05 dla zmiennej G

gretl: prezentacja danych


1960	180.7	184.6	-3.9 *
1961	183.7	185.3	-1.6
1962	186.5	186.8	-0.3
1963	189.2	187.9	1.3
1964	191.9	190.6	1.3
1965	194.3	193.1	1.2
1966	196.6	195.5	1.1
1967	198.7	197.7	1.0
1968	200.7	200.1	0.6
1969	202.7	202.3	0.4
1970	205.1	205.3	-0.2
1971	207.7	207.6	0.1
1972	209.9	209.9	-0.0
1973	211.9	214.0	-2.1
1974	213.9	213.0	0.9
1975	216.0	214.5	1.5
1976	218.0	217.4	0.6
1977	220.2	219.7	0.5
1978	222.6	223.1	-0.5
1979	225.1	224.7	0.4
1980	227.7	226.6	1.1
1981	230.0	230.2	-0.2
1982	232.2	231.1	1.1
1983	234.3	233.6	0.7
1984	236.3	237.9	-1.6
1985	238.5	239.7	-1.2
1986	240.7	242.1	-1.4
1987	242.8	244.0	-1.2
1988	245.0	246.6	-1.6
1989	247.3	249.1	-1.8
1990	249.9	252.4	-2.5
1991	252.6	251.9	0.7
1992	255.4	254.0	1.4
1993	258.1	256.8	1.3
1994	260.7	258.9	1.8
1995	263.2	262.0	1.2

Objaśnienie: * oznacza resztę przekraczającą 2.5 razy błąd standardowy reszt
Miary dokładności prognoz ex post wykorzystano 36 obserwacji


Średni błąd predykcji	ME =	4.2633e-14
Pierwiastek błędu średniokwadr.	RMSE =	1.3512
Średni błąd absolutny	MAE =	1.126
Średni błąd procentowy	MPE =	-0.0045031
Średni absolutny błąd procentowy	MAPE =	0.51253
Współczynnik Theila (w procentach)	U2 =	0.48959

Rysunek 6 prezentacja danych bez G

DOBÓR POSTACI ANALITYCZNEJ MODELU



Rysunek 7 równanie modelu 1 – ze wszystkimi zmiennymi



Rysunek 8 równanie modelu 2 - bez zmiennej G


ESTYMACJA PARAMETRÓW MODELU

$R^2 = 0.997$

R^2 Skorygowane = 0.996

Współczynnik zbieżności = $1 - 0.997 = 0.003$


Do oszacowania parametrów modelu zastosowano klasyczną metodę najmniejszych kwadratów. Metoda ta minimalizuje sumę kwadratów reszt między wartościami rzeczywistymi a teoretycznymi modelu.



Rysunek 9 klasyczna metoda najmniejszych kwadratów- dopasowanie modelu

WERYFIKACJA MODELU

a) Normalność rozkładu reszt




Rysunek 10 wykres rozkładu częstotliwości reszt modelu

W Gretlu wykonano wykres pudełkowy przedstawiający reszty z dopasowaną krzywą normalną (rozkład częstości). Wskazuje on, że rozkład reszt jest zbliżony do normalnego – bez wyraźnej asymetrii.

Na podstawie rozkładu częstości reszt oraz wykresu w Gretlu zaobserwowano, że rozkład reszt jest zbliżony do normalnego. Nie zaobserwowano znaczących odchyłeń od symetrii ani skośności.

Wniosek: Założenie normalności składnika losowego można uznać za spełnione.



Rysunek 11 wykres rozkładu reszt

Test Chi-kwadrat= 8.354, p = 0.0153 wskazuje na statystycznie istotne odchylenie od normalności rozkładu reszt. Jednakże:

- Rozkład reszt jest **wizualnie symetryczny**,
- Nie obserwuje się **istotnej skośności ani kurtozy**,
- Model wykazuje bardzo dobre dopasowanie ($R^2 = 0.997$),
- Wyniki są spójne ekonomicznie.

Wniosek: Możemy uznać, że rozkład jest normalny w dopasowaniu nie 5% tylko 10%. Rozkład reszt można **uznać za akceptowalny**. Model spełnia swoje funkcje predykcyjne i diagnostyczne.

b) Istotność parametrów strukturalnych

W trakcie analizy p-value zauważono, że zmienna G (wydatki rządowe) była statystycznie nieistotna ($p > 0.05$) i została odrzucona z modelu.

Pozostałe zmienne wykazują wysoką istotność ($p < 0.05$), co oznacza, że mają istotny wpływ na zmienną objaśnianą Pop.

c) Test istotności modelu (test F)

Na podstawie wyników regresji oraz wysokiego współczynnika determinacji $R^2 = 0.997$, test F wykazuje istotność całego modelu.

Hipotezy testowe:

- $H_0: R^2 = 0$ (brak związku)
- $H_1: R^2 \neq 0$ (istnieje związek)

Ze względu na wysoką wartość testu F oraz bardzo niski poziom istotności ($p < 0.001$), hipoteza zerowa zostaje odrzucona.

Wniosek: Model jest statystycznie istotny.

d) Autokorelacja składnika losowego (test Durbin-Watsona)

Na podstawie wykresu reszt względem czasu **nie zaobserwowano systematyczności**, co sugeruje brak autokorelacji.


Wskaźnik DW :0.778128

Wniosek: Wartość statystyki Durbin-Watsona wynosi 0.778, co jest znacznie niższe niż wartość neutralna.

Oznacza to, że występuje dodatnia autokorelacja składnika losowego.

Hipoteza alternatywna o dodatniej autokorelacji znajduje potwierdzenie w danych.

Brak podstaw do stwierdzenia ujemnej autokorelacji.



H1: dodatnia autokorelacja składnika losowego
wartość p = 8.85018e-07

H1: ujemna autokorelacja składnika losowego
wartość p = 0.999999

e) Heteroscedastyczność (test White'a i Breuscha-Pagana)

Na wykresie reszt względem wartości dopasowanych nie stwierdzono rosnącej/zmiennej wariancji.

➡ **Wniosek:**

- Przy statystyce testowej $TR^2 = 13.55$ i 9 stopniach swobody, wartość $p \approx 0.1393$.
Ponieważ $p > 0.05$, brak podstaw do odrzucenia hipotezy zerowej o homoskedastyczności składnika losowego. Model nie wykazuje istotnej heteroskedastyczności według testu White'a.
- Test Breuscha-Pagana na heteroskedastyczność wykazał statystykę $LM = 3.49$ ($df = 3$) oraz $p = 0.32$, co oznacza brak podstaw do odrzucenia hipotezy o homoskedastyczności. Warianty składnika losowego można uznać za jednorodne pod względem wariancji.




Test White'a na heteroskedastyczność reszt (zmiennosc wariacji resztowej)
 Estymacja KMNK, wykorzystane obserwacje 1960–1995 (N = 36)
 Zmienna zależna (Y): uhat^2

	współczynnik	błąd standardowy	t-Studenta	wartość p	
const	103.314	42.1066	2.454	0.0212	**
Y	-0.0307261	0.0126899	-2.421	0.0227	**
Pg	27.8682	27.0923	1.029	0.3131	
Ppt	0.713641	25.0141	0.02853	0.9775	
sq_Y	2.31796e-06	9.93137e-07	2.334	0.0276	**
X2_X3	-0.00400402	0.00315037	-1.271	0.2150	
X2_X4	-0.000616525	0.00288720	-0.2135	0.8326	
sq_Pg	0.139919	1.59094	0.08795	0.9306	
X3_X4	3.55988	2.52442	1.410	0.1703	
sq_Ppt	-0.827330	1.39074	-0.5949	0.5571	

Wsp. determ. R-kwadrat = 0.376341

Statystyka testu: $TR^2 = 13.548282$,
 z wartością $p = P(\text{Chi-kwadrat}(9) > 13.548282) = 0.139325$




Test Breuscha-Pagana na heteroskedastyczność
 Estymacja KMNK, wykorzystane obserwacje 1960–1995 (N = 36)
 Zmienna zależna (Y): standaryzowane uhat^2

	współczynnik	błąd standardowy	t-Studenta	wartość p	
const	4.11305	2.10268	1.956	0.0592	*
Y	-0.000512422	0.000315037	-1.627	0.1136	
Pg	0.0115212	0.394468	0.02921	0.9769	
Ppt	0.579766	0.314859	1.841	0.0749	*

Wyjaśniona suma kwadr. = 6.9841

Statystyka testu: LM = 3.492048,
 z wartością $p = P(\text{Chi-kwadrat}(3) > 3.492048) = 0.321795$




Rysunek 12 wykres reszt modelu względem czasu

f) Weryfikacja merytoryczna

Model wykazuje logiczne zależności:

- Wyższy dochód narodowy (Y) i większe wydatki na produkcję (Ppt) pozytywnie wpływają na populację, co jest zgodne z teorią ekonomiczną (lepsze warunki gospodarcze → wzrost demograficzny).
- Ceny konsumpcyjne i producenta również wpływają, lecz umiarkowanie – co może wskazywać na powiązania z inflacją i standardem życia.


➡ **Wniosek:** Model ma sens ekonomiczny i odzwierciedla realne zjawiska gospodarczo-demograficzne.




Rysunek 12 wykres rozrzutu- ocena współliniowości

g) Ocena dopasowania modelu

- $R^2 = 0.997$ – oznacza bardzo dobre dopasowanie modelu do danych (tylko 0.3% wariancji niewyjaśnionej).
- Przedziały ufności dla parametrów są wąskie – wskazuje to na precyzję estymacji.



Rysunek 13 wykres empirycznych i wyrównania względem czasu -pokazanie trafności prognozy



Rysunek 14 przedziały ufności ocen parametrów

ZASTOSOWANIE MODELU I WNIOSKI

Model został wykorzystany do prognozy populacji USA (Pop) na podstawie wybranych zmiennych objaśniających: Y , Ppt , Pg .

Przykładowa prognoza

Dla przykładowych wartości z roku 1990:

- Dochód narodowy (Y) = 11389 mld USD
- Produkt na osobę (Ppt) = 5.197
- Ceny wyd. rządowych (Pg) = 3.834

Po podstawieniu wartości do oszacowanego modelu liniowego:

$$\text{Pop} \approx 126 + 0.009 \cdot Y + 3.86 \cdot Ppt + 1.02 \cdot Pg$$

uzyskano prognozowaną populację na poziomie ok. **252,5 mln osób**, co jest bardzo zbliżone do wartości rzeczywistej z danych.

Interpretacja parametrów

- $\beta_1 (Y)$ – wzrost dochodu narodowego o 1 mld USD powoduje średni wzrost populacji o 0.009 mln osób (czyli 9 tysięcy osób).
- $\beta_2 (Ppt)$ – wzrost produktu na osobę o 1 jednostkę zwiększa populację o około 3.86 mln osób, co sugeruje wpływ standardu życia na decyzje demograficzne.
- $\beta_3 (Pg)$ – wzrost indeksu cen wydatków rządowych o 1 punkt wpływa na wzrost populacji o około 1.02 mln osób, co może odzwierciedlać wpływ polityki publicznej na warunki życia.

Ogólne wnioski z modelu

- Model bardzo dobrze dopasowuje się do danych empirycznych ($R^2 = 0.997$).
- Wszystkie istotne zmienne objaśniające mają sens ekonomiczny i są zgodne z intuicją.
- Można go wykorzystać do szacowania lub prognozowania liczby ludności na podstawie ogólnodostępnych danych makroekonomicznych.

Warto także wykorzystać model do przewidywania wartości Pop dla kolejnych lat po 1995 roku (np. 1996–2000), co stanowiłoby przykład zastosowania modelu do celów predykcyjnych.

BIBLIOGRAFIA

„Dokumentacja programu Gretl” – <https://gretl.sourceforge.net>

„Ekonometria Rozwiązywanie problemów z wykorzystaniem programu GRETL ” – Tadeusz Kufel